

VISIÓN ARTIFICIAL

PROYECTO DE FIN DE CURSO 2014-1

Por: José Miguel Arrieta

Juan Camilo Hincapié

Identificación de problemas mediante adquisición de imágenes fotográficas en soldaduras.

DESCRIPCIÓN DEL PROYECTO

En la actualidad en industrias como la aeronáutica, naval, automovilística, militar, entre otras; el control de calidad se ha hecho vital en aplicaciones críticas donde por un error mínimo en una soldadura puede resultar trágico, arriesgando vidas incluso.

El proceso de inspección de soldaduras, como se desarrolla actualmente requiere de expertos que de manera manual hagan la evaluación de las piezas soldadas, lo cual aparte de tener un alto costo en preparación de parte los expertos, es un proceso que está sometido a problemas como la subjetividad del evaluador, el cansancio y el desgaste físico de este mismo, haciendo de la inspección un proceso costoso y no óptimo.

Actualmente en el campo de la informática y la inteligencia artificial, y con los avances hechos en la rama de la visión artificial, se puede plantear una solución que optimice y solucione los problemas, que aquejan el proceso de inspección actual, y que con la ayuda de técnicas de aprendizaje de máquina, tenga resultados mejores y más precisos cada vez.

Con el presente trabajo, se espera describir las etapas de un sistema de visión artificial que realice la inspección de las soldaduras detectando errores en estas (específicamente salpicaduras), sin estar limitado por la subjetividad, el cansancio y el deterioro físico que está sometido una persona que desempeñe manualmente el proceso de inspección.

ESTADO DEL ARTE

ASSESSMENT OF WELDING DEFECTS FOR GAS PIPELINE RADIOGRAPHS USING COMPUTER VISION.

En este trabajo se introduce un sistema de visión artificial barato para detectar y evaluar defectos de soldadura en tuberías de gas. Se capturaron películas radiográficas donde el sistema mejora las imágenes eliminando la pérdida de detalles de la imagen y permitiendo que los defectos aparezcan más claros capturando características como largo, ancho, área y perímetro.

AUTOMATIC INSPECTION OF GAS PIPELINE WELDING DEFECTS USING AN EXPERT VISION SYSTEM.

En este artículo se presenta un sistema experto de visión para inspección automática de defectos en soldadura de tuberías de gas. Se basa en capturar películas radiográficas, aplicar algoritmos de pre procesamiento y reconocimiento de defectos para después tomar decisiones acorde con los estándares internacionales.

AUTOMATIC INSPECTION SYSTEM OF WELDING RADIOGRAPHIC IMAGES BASED ON ANN UNDER A REGULARISATION PROCESS.

En este trabajo se propone una red neuronal artificial usada en un sistema automático de inspección de defectos en imágenes radiográficas. En una primera etapa técnicas de pre procesamiento de imagen incluyen reducción de ruido, mejoramiento del contraste, umbralización, y etiquetado sirvieron para detectar defectos en soldadura.

En una segunda etapa un set de características geométricas que caracterizan la forma del defecto y la orientación fue propuesto y extraído entre defectos candidatos.

En una tercera etapa una red neuronal artificial para clasificación de defectos fue usado.

El sistema automático de reconocimiento y clasificación propuesto consiste en detectar cuatro tipos de defectos (inclusión de escoria, porosidad, grieta longitudinal, grieta transversal).

DEVELOPMENT OF REAL-TIME LASER-BASED MACHINE VISION SYSTEM TO MONITOR AND CONTROL WELDING PROCESSES

En este estudio un sistema de visión artificial láser es desarrollado e implementado para monitorear y controlar soldaduras. El sistema consiste en tres módulos, módulo de visión basado en sensor láser, módulo de procesamiento de imagen y módulo de control de movimiento multieje. El sistema de visión láser es diseñado y fabricado basado en el principio de la triangulación láser. El módulo de procesamiento es capaz de procesar la imagen capturada por el sensor e identificar las diferentes tipos de juntas de soldadura, información de posición y características geométricas son obtenidas en tiempo real. El módulo de movimiento multi eje se alimenta de estos

datos y ajusta la posición del soplete de soldadura con respecto a la profundidad de las variaciones de la junta de soldadura.

LASER-VISION-BASED QUALITY INSPECTION SYSTEM FOR SMALL-BEAD LASER WELDING

Un sistema de visión laser basado en la cualidad de la soldadura fue desarrollado para medición de la soldadura y detección de defectos. Es diseñado basado en el principio de triangulación láser. Se propone un método rápido para detectar puntos característicos en el rayo láser usando un método de vector de deslizamiento. El sistema permite un perfil en tres dimensiones (3D) de la soldadura para ser reconstruida en tiempo real permitiendo el monitoreo y control de la soldadura, así como inspección de calidad.

VISION INSPECTION SYSTEM FOR THE IDENTIFICATION AND CLASSIFICATION OF DEFECTS IN MIG WELDING JOINTS .

Se habla sobre las limitaciones que tienen algunos sistemas de visión artificial como la inexactitud de las imágenes, no uniformidad de la iluminación, ruido, y contraste deficiente, entonces proponen un sistema de visión artificial de soldaduras en los cuales estos aspectos no serán inconvenientes. Las imágenes son capturadas a través de una cámara CCD. Cuatro cuadros de secuencia de imágenes son obtenidos usando cuatro zonas de leds usando iluminación frontal. Finalmente las juntas de soldadura pueden ser clasificadas usando una red neuronal.

VISION-BASED CLASSIFICATION OF SOLDER JOINTS DEFECTS

Propone una inspección en 2 pasos para mejorar las limitaciones de las técnicas de inspección actuales. Un primer paso llamado "Frontend" donde se normaliza la iluminación de la imagen, localización y segmentación. Gracias a la normalización se pueden eliminar efectivamente los efectos de una iluminación dispareja, salvando las características de la imagen procesada.

Y un segundo paso llamado "Backend" que incluye la clasificación de uniones de soldadura usando el filtro y clasificador Log Gabor. Este filtro ha demostrado tener altos porcentajes de reconocimiento y ser resistente a desalineamientos. A esto sumado que se aplica sobre la transformada discreta Wavelet y la transformada discreta del coseno, lo cual mejora aún más sus resultados.

No se requieren sistemas de iluminación especiales y las imágenes son adquiridas por una cámara digital ordinaria.

DESCRIPCION DE LA SOLUCIÓN


PREPROCESAMIENTO

Para el procesamiento, como primer detalle que notamos, es que las imágenes a evaluar tienen una resolución bastante alta, por lo que consideramos pertinente hacer un redimensionado al 40% del tamaño original, esto sin perder, los detalles que nos interesan en la imagen (las salpicaduras), esto con el fin de agilizar las operaciones sobre la imagen (sobre todo las de vecindad que son las que más tiempo requieren).


Paso seguido procedemos a evaluar la imagen en diferentes espacios de color, a continuación mostramos los resultados obtenidos sobre una imagen a manera de muestra:




Espacio RGB



Espacio CIELAB




Espacio YCbCr




Espacio HSV

De las imágenes anteriores, observamos que en algunos casos algo de la información se perdía (YCbCr), y en otros se generaba mucho ruido (HSV), sin embargo en todas notamos que las salpicaduras se resaltan debido a la iluminación que reciben, marcándose en todos los espacios con un color característico azul en el caso HSV, púrpura en el caso YCbCr y rosa en el espacio CIELAB, en el espacio RGB se marcan con una tonalidad cercana al blanco. Sin embargo los topes de las soldaduras siguen marcándose con la misma característica de las salpicaduras, sin embargo esto no representara un problema posterior ya que su tamaño es mucho mayor al de las salpicaduras por lo que se pueden descartar fácilmente en la extracción de características.

Decidimos escoger el espacio RGB, y pasarlo a escala de grises, con el objetivo de reducir los canales a trabajar y podernos enfocar en la segmentación, además por simplicidad, ya que no tenemos que hacer transformaciones adicionales a la imagen para cambiar de espacio de color.



Escala de grises



Inversa

Al ver la transformación a escala de grises, la imagen nos deja claro entonces que las salpicaduras van a tener formas casi circulares de color blanco, sin embargo para nuestro ojos no es tan sencillo diferenciar las salpicaduras del fondo y de posibles rugosidades o raspaduras de la placa, por lo que extraemos el inverso de la imagen, esperando obtener un mejor resultado, se decide esto ya que la imagen esta contiene gran cantidad de valores grises cercanos al negro y los detalles de la imagen están en tonalidades cercanas al blanco, como lo muestra su histograma.


Además aplicamos un filtro mediana con mascara [5*5] para eliminar imperfecciones de la imagen, sin perder detalles de los bordes de las salpicaduras y de las soldaduras que son las que finalmente nos interesan.



Acto seguido seleccionamos los tonos de gris más cercanos al 0(negro) desde el 50, para de esta manera lograr diferenciar con mayor claridad las salpicaduras, tomando los valores cercanos a el punto de mayor luminosidad (0 en la imagen invertida) y llevándolos a 0, como se aprecia a continuación quedan más resaltados los puntos de interés.


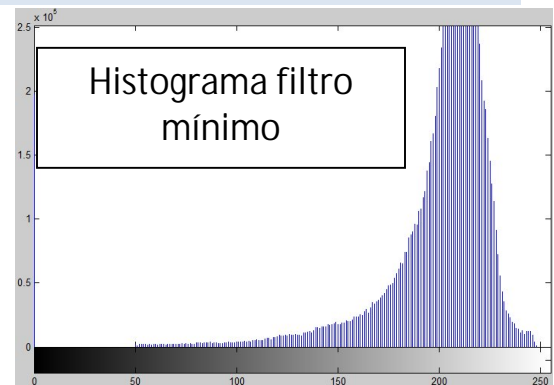


En este punto buscando mejores resultados aplicamos un filtro mínimo con máscara de $[11 \times 11]$ en la imagen inversa modificada, con el objetivo de agrandar los puntos negros de la imagen que representan las salpicaduras, lo cual nos facilitara el proceso de segmentación.



SEGMENTACIÓN

Para la segmentación comenzamos analizando el histograma de la imagen con filtro mínimo (ver imagen anterior), esto con la finalidad de escoger una método de umbralización apropiado. Evaluamos en este caso 3 métodos, umbralización considerando varios valores de umbral automático (multithresh), umbralización automática simple (graythresh) y umbralización simple basado en el histograma.




Multithresh


La imagen tiene varios puntos mínimos, por lo que podríamos considerar el uso de una función como multithresh, para la umbralización considerando varios puntos mínimos, el resultado es bastante bueno a priori, los umbrales seleccionados toman las puntas de las soldaduras y las salpicaduras quedan marcadas con un color azul, mientras el resto de la imagen queda con un color amarillo y cian.

Además debido a que entre 0 y 50

se encuentra el mínimo del histograma, optamos por aplicar graythresh para ver qué resultados obtenemos usando la umbralización automática simple. A primera vista parece buena, sin embargo comparada con el método anterior, detecta mucha basura, marcando con negro detalles de la imagen que no son de nuestro interés como los discos que están en las esquinas de la imagen. En este punto descartamos el uso de este método por esta razón, ya que entorpecería el proceso de clasificación y extracción de características posterior además de inducir a errores.




Graythresh



Umbralización simple

Finalmente intentamos la umbralización por evaluación del histograma, siendo esta la mejor opción, ya que sus resultados son mejores que los del multithresh y no es tan sensible a tonos oscuros y mínimos como el multithresh. Además la simplicidad de uso y su baja complejidad de cómputo, lo ratifican como el método a usar. Para esta umbralización se tomaron todos los píxeles de la imagen mayores que 10 y se llevaron a 255, esta selección se hizo basándonos en el histograma de la imagen después de aplicarse el filtro mínimo.

Finalmente invertimos la imagen para que los puntos de interés nos queden de color blanco, y aplicamos la operación morfológica de dilatación con elemento estructurante 'disk' y máscara de [5*5], con el objetivo de aumentar los puntos que nos interesan y hacerlos más circulares, obteniendo el siguiente resultado.



Dentro del reprocesamiento convertir las imágenes a escalas de grises y hallar el negativo fue muy sencillo, llegar a encontrar la mejor segmentación que se adaptara a los cambios de nivel de luz, además de los distintos ángulos de iluminación de las fotos si es fue más complejo. Sin embargo, fue complicado decidir una manera idónea para identificar las salpicaduras, finalmente notamos que solían estar marcadas por la iluminación es decir tenían puntos donde las luz las hacía más brillantes, por lo que al usar el inverso de la imagen quedarían oscuras o casi negras, de aquí que usáramos un filtro mínimo para lograr que estos puntos se hicieran más notorios (por esto se usa una máscara de 11x11 para lograr crecer más estos puntos) y lograr detectar las salpicaduras más mínimas.

Una de las complicaciones se encuentra en aplicar técnicas de vecindad ya que dependiendo de la máscara el proceso se vuelve muy lento y entorpece probar el código en muchas imágenes.

Entrenamiento:

Extracción de características:

Para el proceso de extracción de características se usaran distintas funciones que nos ayudaran a conseguir características de los objetos de interés en este caso las salpicaduras, nos pueden servir, por ejemplo las funciones para conseguir características geométricas (Bfx_basicgeo), para sacar momentos de Hu (Bfx_hugeo), momentos de Flusser (Bfx_flusser), descriptores de Fourier(Bfx_fourierdes), momentos estadísticas (Bfx_moments), Momentos de gupta (Bfx_gupta).

También nos puede interesar sacar características de intensidad, por lo cual necesitaremos una imagen en escala de grises, para este caso las características que sacamos y las funciones que usamos fueron por ejemplo: Características de intensidad estándar (Bfx_basicint), Momentos de HU con intensidad (Bfx_huint), Características DCT(Bfx_dct), Característica de textura de patrón local binario(Bfx_lbp), Características de contraste (Bfx_contrast).

En resumen las características que se extraerán serán las siguientes (78 en total):


center of grav i [px]	Hu-moment 4	G-Intensity Skewness	G-wsLBP(8,1)[8x8]
center of grav j [px]	Hu-moment 5	G-Mean Laplacian	G-wsLBP(9,1)[8x8]
Height [px]	Hu-moment 6	G-Mean Boundary Gradient	G-wsLBP(10,1)[8x8]
Width [px]	Hu-moment 7	G-Hu-moment-int 1	G-wsLBP(11,1)[8x8]
Area [px]	Flusser-moment 1	G-Hu-moment-int 2	G-wsLBP(12,1)[8x8]
Perimeter [px]	Flusser-moment 2	G-Hu-moment-int 3	G-wsLBP(13,1)[8x8]
Roundness	Flusser-moment 3	G-Hu-moment-int 4	G-wsLBP(14,1)[8x8]
Danielsson factor	Flusser-moment 4	G-Hu-moment-int 5	G-wsLBP(15,1)[8x8]
Euler Number	Moment 0,0	G-Hu-moment-int 6	G-wsLBP(16,1)[8x8]
Equivalent Diameter [px]	Moment 1,0	G-Hu-moment-int 7	G-wsLBP(17,1)[8x8]
MajorAxisLength [px]	Moment 0,1	G-DCT(1,1)	G-contrast-K1
MinorAxisLength [px]	Fourier-des 1	G-DCT(1,2)	G-contrast-K2
Orientation [grad]	Fourier-des 2	G-DCT(2,1)	G-contrast-K3
Solidity	Fourier-des 3	G-DCT(2,2)	G-contrast-Ks
Extent	Fourier-des 4	G-wsLBP(1,1)[8x8]	G-contrast-K
Eccentricity	Gupta-moment 1	G-wsLBP(2,1)[8x8]	
Convex Area [px]	Gupta-moment 2	G-wsLBP(3,1)[8x8]	
Filled Area [px]	Gupta-moment 3	G-wsLBP(4,1)[8x8]	

Hu-moment 1	G-Intensity Mean	G-wsLBP(5,1)[8x8]
Hu-moment 2	G-Intensity StdDev	G-wsLBP(6,1)[8x8]
Hu-moment 3	G-Intensity Kurtosis	G-wsLBP(7,1)[8x8]

Etiquetado de Objetos

Esta es la pare humana y visual que interviene en el proceso de entrenamiento, se crearan las matrices X (matriz de características) y d (clasificación ideal).

Clase 1: Salpicadura. Clase 2: No salpicadura.



Este proceso se realizó entonces con las primeras 52 imágenes (cada imagen con maso menos 70 objetos por etiquetar), por lo cual fue un proceso largo y engorroso, ya que aunque dilatamos la imagen existen muchos puntos de salpicadura bastantes pequeños y abundantes.

En este paso ya tenemos una matriz X (Filas:3129, Columnas:78) con la información de todas las imágenes de prueba la cual más adelante debemos depurar y seleccionar las mejores; y un vector d (Filas:3129, Columnas:1) con la clasificación ideal.

Selección de características:

Se realizó entonces un proceso de limpieza de las características quitando las que estén correlacionadas o sean constantes, reduciendo así de 78 a 63 características.

Se probara entonces los métodos SFS , PCA y PLSR con distintos números de características probando el desempeño usando un clasificador LDA sobre el mismo conjunto de datos.

Los resultados se resumen en la siguiente tabla:

	n=1	n=2	n=4	n=8	n=10	n=20	n=22	n=25
SFS	78,460	84,788	85,682	86,737	86,993	87,121	1,000	1,000
PCA	80,026	79,962	80,217	80,249	80,281	84,372	1,000	1,000
PLSR	82,550	85,906	86,513	86,961	86,897	87,408	1,000	1,000

Todos estos métodos tienen un desempeño similar cuando se escogen ya sea más de 20 características o más de 20 componentes principales, por lo cual el método de selección que se usara en el sistema de visión será el más simple y con mejor rendimiento en este caso SFS con 22 características.

Detección y clasificación de los defectos

Para la clasificación de los defectos se usaron los métodos

Y se resume sus desempeños en la siguiente tabla

Tabla :

Numero Caracteristicas	LDA	Mahalanobis	Cuadrático	<u>red neuronal</u>	K-NN(3 vecinos)	K-NN(5 vecinos)
22	0,8712	0,6558	0,8555	0,8668	0,8153	0,8227

Podemos observar que el clasificador que mejor resultado obtuvo y el más simple además es el LDA , por lo cual será el seleccionado, recordar que estamos buscando clasificar solo dos clases y se puede corroborar que el LDA es una buena opción.

Resultados en términos de falsos positivos y falsos negativos

De los datos que se tienen X y d se parte entonces en dos pedazos uno con un 75% con los cuales se entrenaran los clasificadores y otro 25% en los cuales se harán las pruebas.

Se muestra entonces las matrices de confusión para cada uno de los clasificadores :

LDA

T =

78 99

p =

0.8694

Mahalanobis

T =

378 226

21 156

p =

0.6837

QDA

T =

569 35

75 102

p =

0.8592

Nueral network

T =

575 29

75 102

p =

0.8668

K-NN(3 vecinos)

T =

564 40

106 71

p =

0.8131

K-NN(5 vecinos)

T =

577 27

110 67

p =

0.8246

LDA es la que tiene menos falsos negativos y la segunda en tener menos falsos positivos, además de tener el valor p más cercano a 1.

Discusión:

El paso más largo y exhaustivo fue etiquetar los objetos, ya que en las imágenes hay muchos puntos de salpicadura y muchos también probables por lo cual hacerlo uno por uno siendo estos tan pequeños es bastante engorroso en una gran cantidad de imágenes, después de esto el proceso de extracción de características consume bastante tiempo de computo por los métodos implementados, esto se pudo sobrellevar utilizando dos computadores al tiempo y etiquetando en varias máquinas.

La parte de escoger las mejores características es relativamente sencillo de computar, y también las de entrenar los clasificadores.

Conclusiones:

Se pudo implementar un sistema de visión artificial con la mayoría de sus pasos, desde el pre procesamiento hasta la detección de patrones y clasificación, en un problema abierto como es la detección de defectos en soldadura específicamente salpicadura donde los resultados fueron satisfactorios, utilizando las herramientas aprendidas en clase.

Referencias:

G. Senthil, K., U, N., & S. S., A. (December 2011). Vision inspection system for the identification. Springer.

Gas, M. v. (2014). En R. U, P. M, B. G, & W. K. International Institute of Welding.

H, S., E, G., A, A.-S., & I.M, E. (2003). Assessment of welding defects for gas pipeline radiographs. Elsevier Ltd.

H.I.Shafeeka, EGadelmawlab, Abdel-Shafyb, & I.M, E. (2011). Automatic inspection of gas pipeline welding defects. Elsevier Ltd.

Huu-Cuong, N., & Byung-Ryong, L. (s.f.). Laser-Vision-based Quality Inspection System for Small-.

Juan, Z., Rafael, V., & Ramón, R. (2011). Automatic Inspection System of Welding Radiographic Images. Springer Science+Business Media.

Wei, H., & Radovan, K. (2012). Development of a real-time laser-based machine vision system.

Siri,N. (April 2010). Vision-Based classification of solder joints defects.